Universidad del Valle de Guatemala
Data Science - CC3066 - Sección 20
Catedrático: LUIS ROBERTO FURLAN COLLVER

Integrantes:
JULIO ROBERTO HERRERA SABAN
OSCAR RENE SARAVIA DONIS
DIEGO DE JESUS ARREDONDO TURCIOS

Laboratorio 5
Análisis de Sentimientos

Link del Repositorio: https://github.com/arr19422/Lab5-DS

(15 puntos) Análisis exploratorio

El *dataset* utilizado fue adquirido de Kaggle: Natural Language Processing with Disaster Tweets y se generó un reporte al *dataset* sin procesamiento.

Reporte:

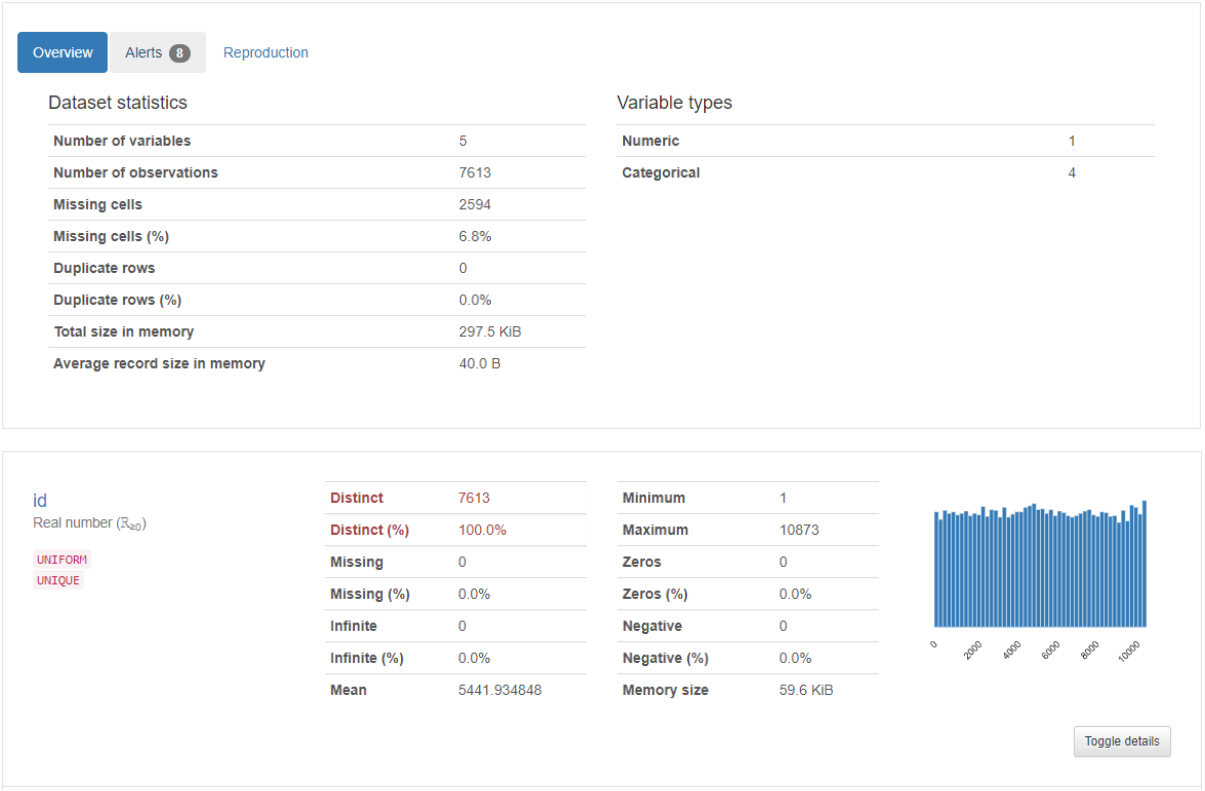

Overview | Alerts 8 | Reproduction

Dataset statistics

Number of variables	5
Number of observations	7613
Missing cells	2594
Missing cells (%)	6.8%
Duplicate rows	0
Duplicate rows (%)	0.0%
Total size in memory	297.5 KiB
Average record size in memory	40.0 B

Variable types

Numeric	1
Categorical	4

id
Real number (ℝ≥0)

UNIFORM
UNIQUE

Distinct	7613
Distinct (%)	100.0%
Missing	0
Missing (%)	0.0%
Infinite	0
Infinite (%)	0.0%
Mean	5441.934848

Minimum	1
Maximum	10873
Zeros	0
Zeros (%)	0.0%
Negative	0
Negative (%)	0.0%
Memory size	59.6 KiB

Toggle details

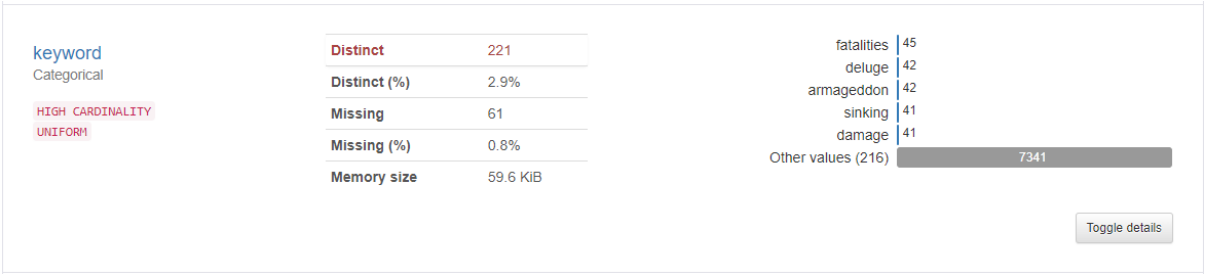

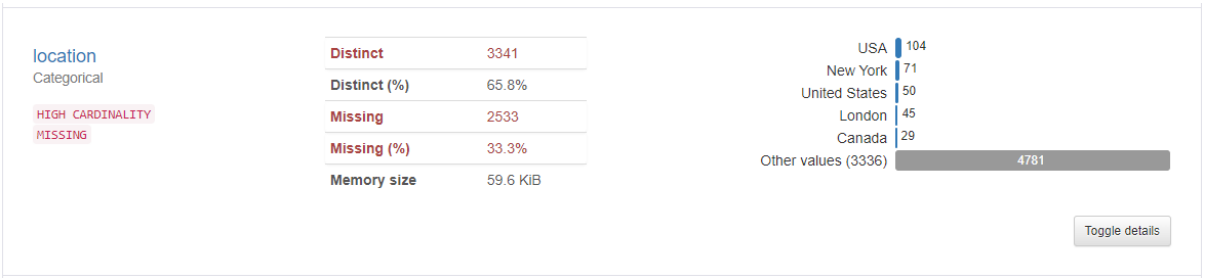

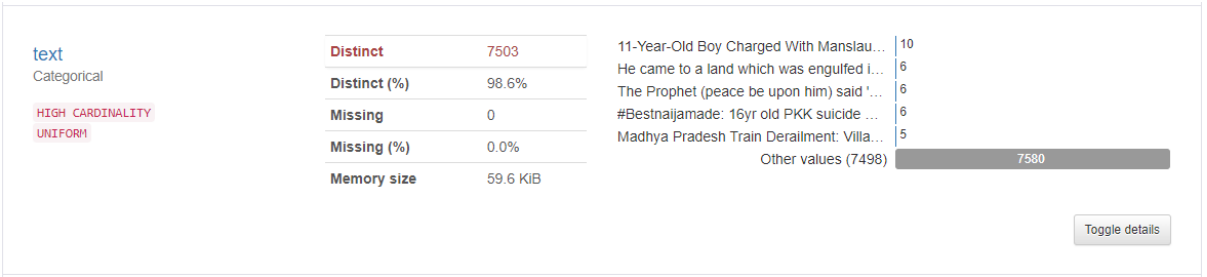

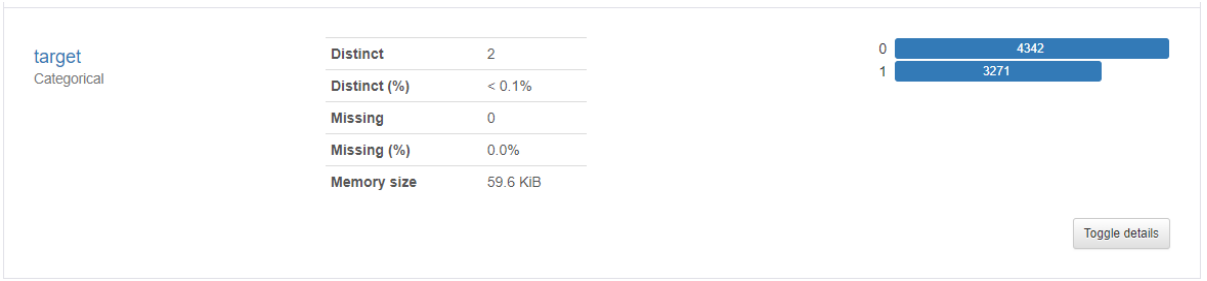

Las variables del dataset representan lo siguiente:

- id: Identificador del tweet.
- keyword: Palabra clave del tweet.
- location: Ubicación desde donde se envió el tweet.
- text: Cuerpo del tweet.
- target: Variable boolean que es verdadero si el tweet habla de un desastre real y falso si no.

Como podemos ver, las variables *keyword* y *location* tienen 0.8% y 33.3% de valores vacíos sin embargo, no se removerán estas observaciones ya que si bien podemos obtener conclusiones de ellas, es la variable *text* la que nos importa para realizar la clasificación.

Hallazgos:

Algunas hallazgos encontrados por medio de gráficas a las variables son:

La ubicación desde donde más se tweeteó fue USA, sin embargo hay distintos valores que representan a este mismo país ya que también se encuentra como United States o como todos los estados específicos del país como New York, Los Angeles, CA y Washington, DC que se encuentran también entre el top 11 de ubicaciones más repetidas.

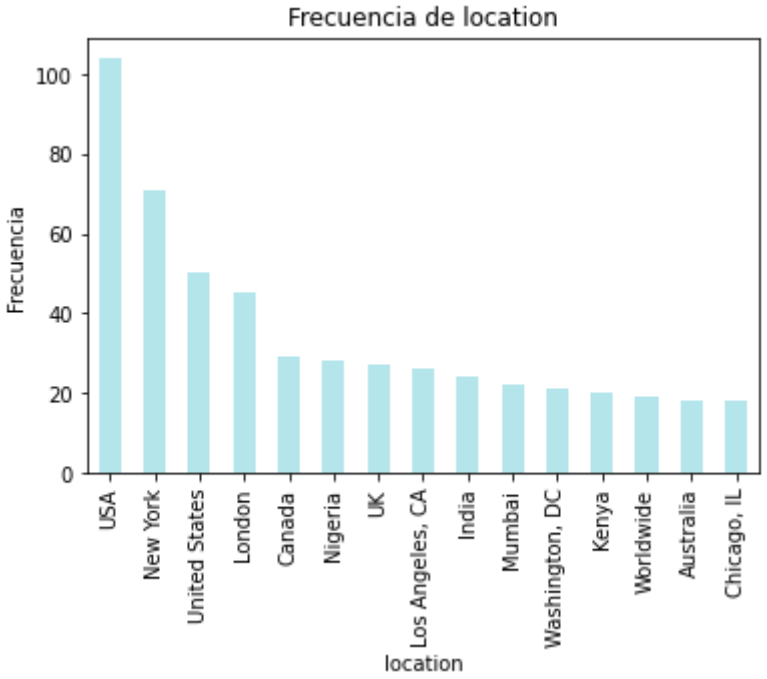

Las palabras clave (*keywords*) tienen una distribución más uniforme, repitiéndose más de la mitad de las observaciones entre 30 y 45 veces. Se puede observar que entre el top 15 de palabras más frecuentes como *keywords* están relacionadas con algún hecho trágico. También se observa que algunos valores pueden estar conformados realmente por más de una palabra pero siendo el espacio representado por “%20” normalmente utilizado para hacer *encoding* de URLs.

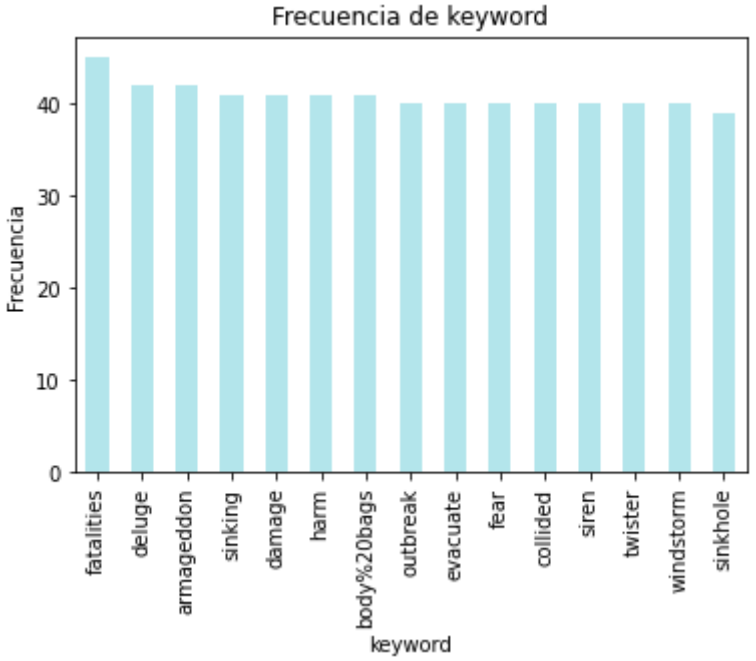

La variable *target* es la que nos ayudará a entrenar el modelo y clasificar si se habla de un desastre real o no. Esta es la variable que no se encuentra en el *dataset* de *testeo* y en este de entrenamiento muestra que existe mayoría de tweets que no hablan de un desastre real, sin embargo es una distribución bastante buena.

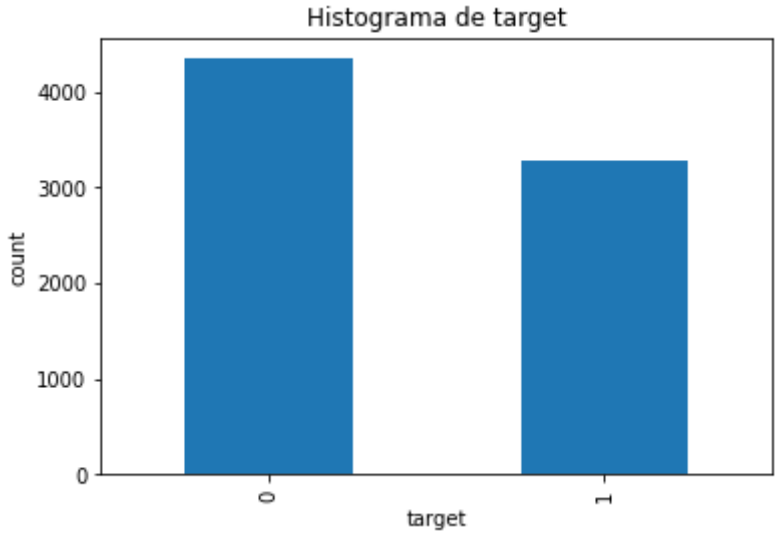

En cuanto al *dataset* de *testeo* se observó un comportamiento parecido en las variables *location* y *keywords* con algunas diferencias en las posiciones de los valores con más frecuencia.

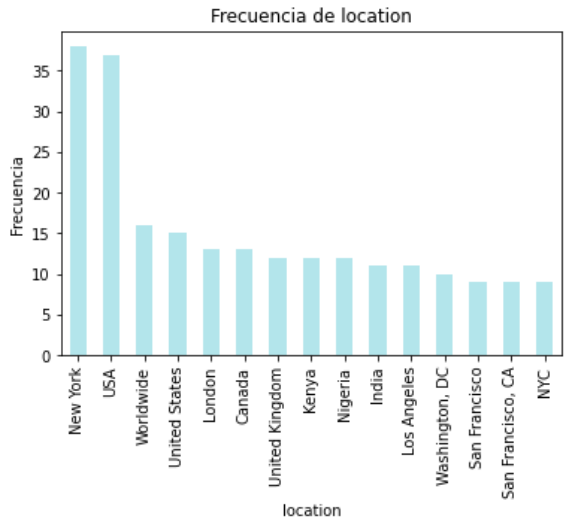

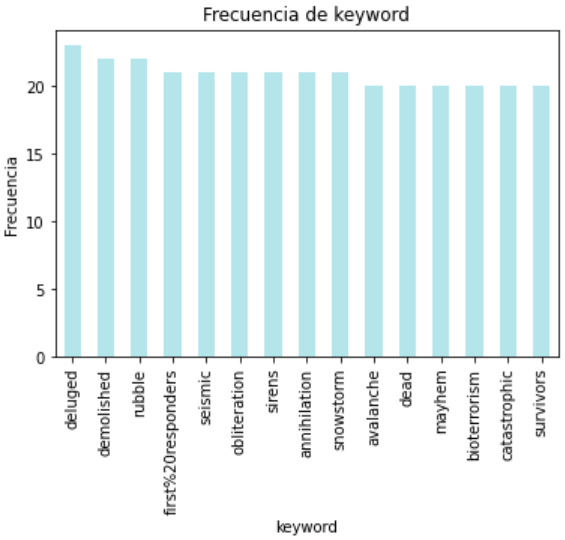

(15 puntos) Limpieza y procesamiento de los datos

Primero se convirtieron todos los datos a minúsculas:

Convirtiendo a minúsculas

```
for i in range(len(train)):
    train.loc[i,'text'] = train.loc[i,'text'].lower()

for i in range(len(test)):
    test.loc[i,'text'] = test.loc[i,'text'].lower()
```

✓ 2.1s

```
train.head()
```

✓ 0.6s

	id	keyword	location	text	target
0	1	NaN	NaN	our deeds are the reason of this #earthquake m...	1
1	4	NaN	NaN	forest fire near la ronge sask. canada	1
2	5	NaN	NaN	all residents asked to 'shelter in place' are ...	1
3	6	NaN	NaN	13,000 people receive #wildfires evacuation or...	1
4	7	NaN	NaN	just got sent this photo from ruby #alaska as ...	1

```
test.head()
```

✓ 0.4s

	id	keyword	location	text
0	0	NaN	NaN	just happened a terrible car crash
1	2	NaN	NaN	heard about #earthquake is different cities, s...
2	3	NaN	NaN	there is a forest fire at spot pond, geese are...
3	9	NaN	NaN	apocalypse lighting. #spokane #wildfires
4	11	NaN	NaN	typhoon soudelor kills 28 in china and taiwan

Luego se quitaron los URLs:

Quitando urls

```
#Quitar las urls
for i in range(len(train)):
    train.loc[i,'text'] = re.sub(r'((http|https)\:\/\/)?[a-zA-Z0-9\.\/\?\:@\-_=#]+\.([a-zA-Z]){2,6}([a-zA-Z0-9\.\&\/\?\:@\-_=#])*', "", train.loc[i,'text'])

for i in range(len(test)):
    test.loc[i,'text'] = re.sub(r'((http|https)\:\/\/)?[a-zA-Z0-9\.\/\?\:@\-_=#]+\.([a-zA-Z]){2,6}([a-zA-Z0-9\.\&\/\?\:@\-_=#])*', '', test.loc[i,'text'])
```

✓ 2.2s

```
train.head()
```

✓ 0.5s

	id	keyword	location	text	target
0	1	NaN	NaN	our deeds are the reason of this #earthquake m...	1
1	4	NaN	NaN	forest fire near la ronge sask. canada	1
2	5	NaN	NaN	all residents asked to 'shelter in place' are ...	1
3	6	NaN	NaN	13,000 people receive #wildfires evacuation or...	1
4	7	NaN	NaN	just got sent this photo from ruby #alaska as ...	1

```
test.head()
```

✓ 0.4s

	id	keyword	location	text
0	0	NaN	NaN	just happened a terrible car crash
1	2	NaN	NaN	heard about #earthquake is different cities, s...
2	3	NaN	NaN	there is a forest fire at spot pond, geese are...
3	9	NaN	NaN	apocalypse lighting. #spokane #wildfires
4	11	NaN	NaN	typhoon soudelor kills 28 in china and taiwan

Seguidamente se quitaron signos de puntuación y los caracteres especiales:

Eliminando signos de puntuación y caracteres especiales (@, #, $, %, etc.)

```
#Se eliminan los signos de puntuacion
for i in range(len(train)):
    train.loc[i,'text'] = train.loc[i,'text'].translate(str.maketrans(string.punctuation, ' ' * len(string.punctuation)))


for i in range(len(test)):
    test.loc[i,'text'] = test.loc[i,'text'].translate(str.maketrans(string.punctuation, ' ' * len(string.punctuation)))
```

✓ 2.2s

```
train.head()
```

✓ 0.4s

	id	keyword	location	text	target
0	1	NaN	NaN	our deeds are the reason of this earthquake m...	1
1	4	NaN	NaN	forest fire near la ronge sask canada	1
2	5	NaN	NaN	all residents asked to shelter in place are ...	1
3	6	NaN	NaN	13 000 people receive wildfires evacuation or...	1
4	7	NaN	NaN	just got sent this photo from ruby alaska as ...	1

```
test.head()
```

✓ 0.6s

	id	keyword	location	text
0	0	NaN	NaN	just happened a terrible car crash
1	2	NaN	NaN	heard about earthquake is different cities s...
2	3	NaN	NaN	there is a forest fire at spot pond geese are...
3	9	NaN	NaN	apocalypse lighting spokane wildfires
4	11	NaN	NaN	typhoon soudelor kills 28 in china and taiwan

Luego se quitaron los stopwords, definiendo el idioma inglés.

Definiendo stopwords en idioma inglés Quitando las stopwords (the, a, an, etc.)

```
#Ref: https://www.delftstack.com/howto/python/remove-stop-words-in-python/#:~:text=The%20nlkt%20(Natural%20Language%20Processing,the%20list%20from%20this%20library.
#Quitar las stopwords
stopWords = stopwords.words('english')

for i in range(len(train)):
    train.loc[i,'text'] = ' '.join(word for word in train.loc[i,'text'].split() if word not in stopWords)

for i in range(len(test)):
    test.loc[i,'text'] = ' '.join(word for word in test.loc[i,'text'].split() if word not in stopWords)
```

✓ 2.5s

```
train.head()
```

✓ 0.4s

	id	keyword	location	text	target
0	1	NaN	NaN	deeds reason earthquake may allah forgive us	1
1	4	NaN	NaN	forest fire near la ronge sask canada	1
2	5	NaN	NaN	residents asked shelter place notified officer...	1
3	6	NaN	NaN	13 000 people receive wildfires evacuation ord...	1
4	7	NaN	NaN	got sent photo ruby alaska smoke wildfires pou...	1

```
test.head()
```

✓ 0.4s

	id	keyword	location	text
0	0	NaN	NaN	happened terrible car crash
1	2	NaN	NaN	heard earthquake different cities stay safe ev...
2	3	NaN	NaN	forest fire spot pond geese fleeing across str...
3	9	NaN	NaN	apocalypse lighting spokane wildfires
4	11	NaN	NaN	typhoon soudelor kills 28 china taiwan

Posteriormente se quitan los emojis:

```
train.head()
```

✓ 0.4s

	id	keyword	location	text	target
0	1	NaN	NaN	deeds reason earthquake may allah forgive us	1
1	4	NaN	NaN	forest fire near la ronge sask canada	1
2	5	NaN	NaN	residents asked shelter place notified officer...	1
3	6	NaN	NaN	13 000 people receive wildfires evacuation ord...	1
4	7	NaN	NaN	got sent photo ruby alaska smoke wildfires pou...	1

```
test.head()
```

✓ 0.4s

	id	keyword	location	text
0	0	NaN	NaN	happened terrible car crash
1	2	NaN	NaN	heard earthquake different cities stay safe ev...
2	3	NaN	NaN	forest fire spot pond geese fleeing across str...
3	9	NaN	NaN	apocalypse lighting spokane wildfires
4	11	NaN	NaN	typhoon soudelor kills 28 china taiwan

Y por último, se quitan los números, pero se decidió dejar el 911 por futura utilidad al momento de analizar los datos

Quitando números excepto el 911

```
#Quitar numeros, se considera dejar el 911 ya que es un numero representativo en EEUU y puede ser de utilidad
for i in range(len(train)):
    train.loc[i,'text'] = re.sub(r'#\S+|\d+', lambda match: match.group(0) if match.group(0).startswith('911') else '', train.loc[i,'text'])

for i in range(len(test)):
    test.loc[i,'text'] = re.sub(r'#\S+|\d+', lambda match: match.group(0) if match.group(0).startswith('911') else '', test.loc[i,'text'])
```

✓ 2.2s

```
train.head()
```

✓ 0.4s

	id	keyword	location	text	target
0	1	NaN	NaN	deeds reason earthquake may allah forgive us	1
1	4	NaN	NaN	forest fire near la ronge sask canada	1
2	5	NaN	NaN	residents asked shelter place notified officer...	1
3	6	NaN	NaN	people receive wildfires evacuation orders c...	1
4	7	NaN	NaN	got sent photo ruby alaska smoke wildfires pou...	1

```
test.head()
```

✓ 0.4s

	id	keyword	location	text
0	0	NaN	NaN	happened terrible car crash
1	2	NaN	NaN	heard earthquake different cities stay safe ev...
2	3	NaN	NaN	forest fire spot pond geese fleeing across str...
3	9	NaN	NaN	apocalypse lighting spokane wildfires
4	11	NaN	NaN	typhoon soudelor kills china taiwan

Durante todo este proceso pudimos ir viendo cómo cambiaban - al menos - las primeras observaciones en su columna *text*, por lo que comprobamos que los valores en ambos datasets fueron arreglados según lo indicado.

(20 puntos) Clasificación de Palabras

Primero separamos los tweets que son de desastres reales y los que no a partir del valor de la variable *target*.

Frecuencia de tweets de desastres

```
disaster_freq = train[train['target'] == 1]
disaster_words = []
for i in range(len(disaster_freq)):
    text = disaster_freq.iloc[i]['text'].split()
    for word in text:
        disaster_words.append(word)

keywords = " ".join(review for review in disaster_words)
wordcloud = WordCloud(stopwords=stopwords, background_color="white").generate(keywords)
plt.figure( figsize=(15,10))
plt.imshow(wordcloud, interpolation='bilinear')
plt.axis("off")
plt.show()
```

✓ 0.6s

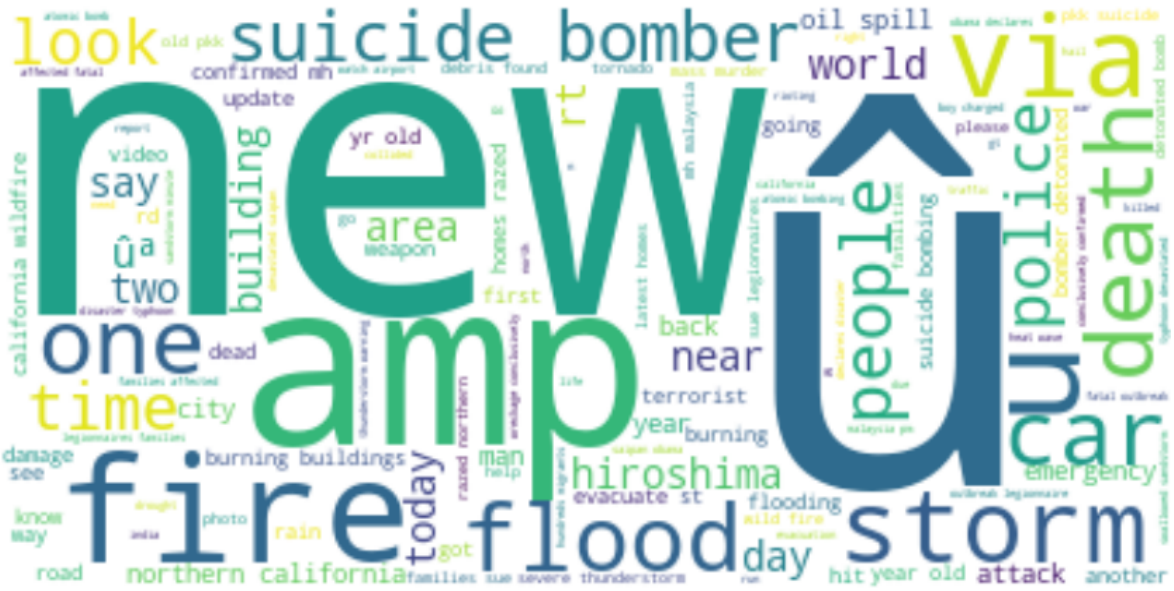

Frecuencia de tweets de no desastres

```
not_disaster_freq = train[train['target'] == 0]
not_disaster_words = []
for i in range(len(not_disaster_freq)):
    text = not_disaster_freq.iloc[i]['text'].split()
    for word in text:
        not_disaster_words.append(word)

keywords = " ".join(review for review in not_disaster_words)
wordcloud = WordCloud(stopwords=stopwords, background_color="white").generate(keywords)
plt.figure( figsize=(15,10))
plt.imshow(wordcloud, interpolation='bilinear')
plt.axis("off")
plt.show()
```

✓ 0.8s

Analizando bigramas

+ Code

```
# https://towardsdatascience.com/text-analysis-basics-in-python-443282942ec5
def get_bigrams(text):
    count_vectorizer = CountVectorizer(ngram_range=(2, 2))
    ngrams = count_vectorizer.fit_transform(text)
    count_values = ngrams.toarray().sum(axis=0)
    vocab = count_vectorizer.vocabulary_
    df_ngram = pd.DataFrame(sorted([(count_values[i], k) for k, i in vocab.items(
    )], reverse=True)).rename(columns={0: 'frequency', 1: 'bigram'})
    return df_ngram

plt.figure(figsize=(10, 5))
bigrams = get_bigrams(train['text'])
x = bigrams['frequency'][:15]
y = bigrams['bigram'][:15]
sns.barplot(x=x, y=y)
```

✓ 1.3s

```
<AxesSubplot:xlabel='frequency', ylabel='bigram'>
```

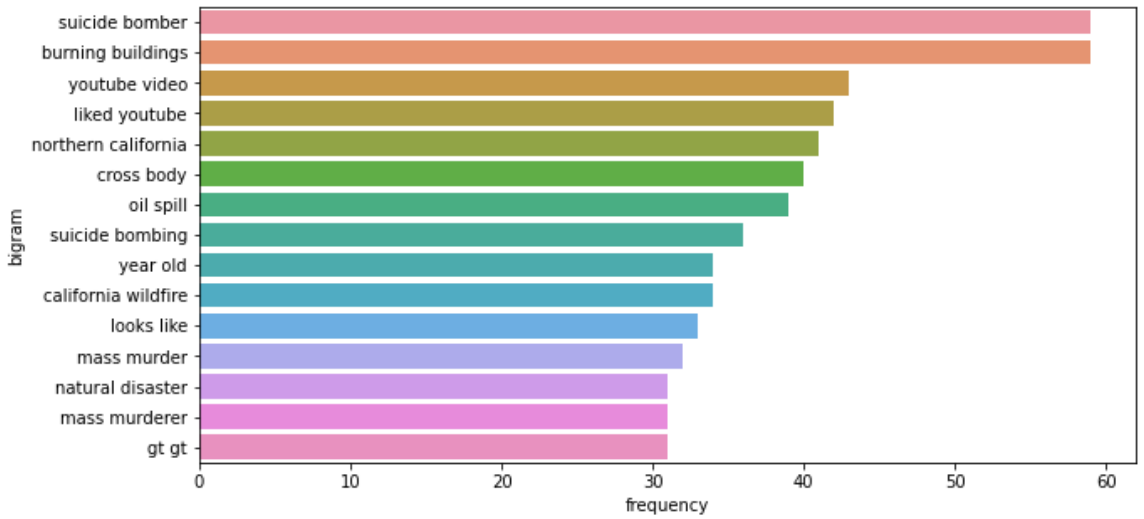

Analizando trigramas

```
# https://towardsdatascience.com/text-analysis-basics-in-python-443282942ec5
def get_trigrams(text):
    count_vectorizer = CountVectorizer(ngram_range=(3, 3))
    ngrams = count_vectorizer.fit_transform(text)
    count_values = ngrams.toarray().sum(axis=0)
    vocab = count_vectorizer.vocabulary_
    df_ngram = pd.DataFrame(sorted([(count_values[i], k) for k, i in vocab.items(
    )], reverse=True)).rename(columns={0: 'frequency', 1: 'trigrams'})
    return df_ngram

plt.figure(figsize=(10, 5))
trigrams = get_trigrams(train['text'])
x = trigrams['frequency'][:15]
y = trigrams['trigrams'][:15]
sns.barplot(x=x, y=y)
```

✓ 1.3s

```
<AxesSubplot:xlabel='frequency', ylabel='trigrams'>
```

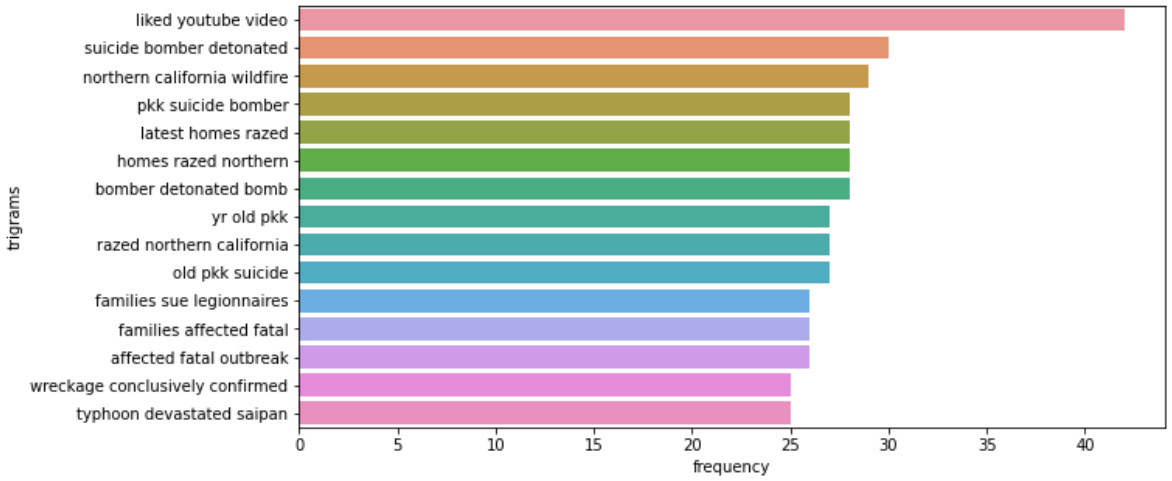

(10 puntos) Clasificación de tweets en positivo, negativo y neutro.

```
train.head()
```
✓ 0.9s

	id	keyword	location	text	target	score	sentiment
0	1	NaN	NaN	deeds reason earthquake may allah forgive us	1	0.2732	neutral
1	4	NaN	NaN	forest fire near la ronge sask canada	1	-0.3400	neutral
2	5	NaN	NaN	residents asked shelter place notified officer...	1	0.0000	neutral
3	6	NaN	NaN	people receive wildfires evacuation orders c...	1	0.0000	neutral
4	7	NaN	NaN	got sent photo ruby alaska smoke wildfires pou...	1	0.0000	neutral

```
test.head()
```
✓ 0.4s

	id	keyword	location	text	score	sentiment
0	0	NaN	NaN	happened terrible car crash	-0.7003	negative
1	2	NaN	NaN	heard earthquake different cities stay safe ev...	0.4404	neutral
2	3	NaN	NaN	forest fire spot pond geese fleeing across str...	-0.6159	negative
3	9	NaN	NaN	apocalypse lighting spokane wildfires	0.0000	neutral
4	11	NaN	NaN	typhoon soudelor kills china taiwan	-0.5423	negative

Cree una variable que contenga la "negatividad" de cada tweet. Inclúyala en el conjunto de datos y entrene nuevamente el modelo de clasificación de la hoja pasada.

¿La inclusión de esta variable mejoró los resultados del modelo de clasificación?

Se agregó la variable score a cata uno de las filas en el conjunto de datos, mejoró los resultados ya que nos permitió medir cuantitativamente que tan positivos o negativos son los tweets, lo cual nos permite poder identificar con mayor facilidad dentro de que clasificación entra cada uno de ellos y también poder determinar los principales temas de los tweets positivos y negativos.

Resultados

7.1. ¿Cuáles son los 10 tweets más negativos?¿En qué categoría están?

La mayoría de los 10 tweets más negativos están dentro de la categoría de catástrofes reales, por ejemplo atentados con bombas y situaciones donde hubieron múltiples personas heridas. Por otro lado, una pequeña parte de los tweets se clasifican dentro de la categoría de cosas que no ocurrieron pero hablan acerca del miedo y el terror.

	id	keyword	location	text	target	score	sentiment
7472	10689	wreck	NaN	wreck wreck wreck wreck wreck wreck wrec...	0	-0.9879	negative
2844	4089	displaced	NaN	peterjukes crime killed displaced millions sys...	1	-0.9652	negative
6411	9166	suicide bomber	NaN	suicide bomber kills saudi security site mosq...	1	-0.9623	negative
6393	9137	suicide bomb	Worldwide	th day since jul nigeria suicide bomb attack...	1	-0.9595	negative
5240	7493	obliteration	23 countries and counting!	fear mind killer fear little death brings tota...	0	-0.9552	negative
6407	9159	suicide bomber	Worldwide	killed s□ûªarabia mosque suicide bombing suic...	1	-0.9552	negative
472	682	attack	portland, oregon	illegal alien released obama dhs times charge...	1	-0.9538	negative
1540	2225	chemical emergency	Las Vegas, Nevada	bomb crash loot riot emergency pipe bomb nucle...	1	-0.9524	negative
6930	9940	trouble	NaN	cspan prez mr president biggest terrorist trou...	1	-0.9493	negative
2932	4213	drowned	Pembroke NH	lake sees dead fish poor little guy wonder hap...	0	-0.9477	negative

7.2. ¿Cuáles son los 10 tweets más positivos? ¿En qué categoría están?

En cuanto a los 10 tweets más positivos, podemos encontrar que las categorías hablan sobre situaciones reales y sobre deseos de las personas

	id	keyword	location	text	target	score	sentiment
6992	10028	twister	NaN	check want twister tickets vip experience see ...	0	0.9682	positive
3163	4541	emergency	Renfrew, Scotland	batfanuk enjoyed show today great fun emergenc...	0	0.9423	positive
3382	4844	evacuation	Renfrew, Scotland	batfanuk enjoyed show today great fun emergenc...	0	0.9423	positive
6292	8989	storm	NaN	today□ûªs storm pass let tomorrow□ûªs light gr...	1	0.9403	positive
7182	10291	weapon	NaN	roguewatson nothing wrong lethal weapon series...	0	0.9365	positive
344	493	armageddon	#FLIGHTCITY UK	official vid thereal gt gt gt gt gt gt trubgme...	0	0.9313	positive
2238	3198	deluge	NaN	meditationbymsg ppl got method meditation u p...	0	0.9287	positive
6295	8994	stretcher	NaN	free ebay sniping rt lumbar extender back stre...	0	0.9260	positive
6560	9386	survived	Puerto Rico	duchovbutt starbuck scully madmakny davidducho...	0	0.9217	positive
4154	5903	harm	Gotham City	never escape bullets harm nothing harms know p...	1	0.9196	positive

7.3. ¿Son los tweets de la categoría que indica que habla de un desastre real más negativos que los de la otra categoría?

Los tweets que hablan más acerca de desastres reales si tienen una puntuación más negativa que aquellos tweets que no describen una situación real. Como se puede observar en la imágen de los primeros 5 tweets, 3 de ellos son reales, como lo indica la variable target.

Referencias

Akladyous, Boula. (2021). entiment Analysis using VADER. Medium. Extraído de: https://akladyous.medium.com/sentiment-analysis-using-vader-c56bcffe6f24

Yang, Sophia. (2020). Text analysis basics in Python. Towards Data Science. Extraído de: https://towardsdatascience.com/text-analysis-basics-in-python-443282942ec5